

utfcode
utf8.sty 3.10 UTF-8 input encoding 13.06.2000
scanner for code UTF-8 installed.

Analysis Camda 2023 - Synthetic Clinical Health Records Challenge

violeta calles

August 2026

1. Introducción

CAMDA (Critical Assessment of Massive Data Analysis) es una conferencia científica que funciona como una pista permanente dentro de ISMB, en colaboración con ECCB, y está centrada en uno de los grandes retos actuales: la explotación inteligente de datos masivos en ciencias de la vida. Cada edición propone varios retos abiertos de análisis de datos sobre conjuntos reales o sintéticos, entre los que en 2023 se incluyó el Synthetic Clinical Health Records Challenge, centrado en registros clínicos electrónicos de pacientes diabéticos.

Este reto ofrece un conjunto de historiales clínicos electrónicos (EHR) altamente realistas que recogen la trayectoria diagnóstica de pacientes diabéticos, generados mediante un enfoque de autoencoders adversarios duales (DAAE) entrenado con datos de pacientes reales de la Base Poblacional de Salud (BPS) del Servicio Andaluz de Salud. Concretamente, los datos sintéticos se generaron a partir de una cohorte real de 979.308 pacientes diabéticos, dando lugar a un dataset con la lista ordenada de patologías de 999.936 pacientes sintéticos. Al tratarse de datos generados artificialmente a partir de una población real, el dataset preserva patrones clínicos y epidemiológicos plausibles sin comprometer la privacidad de los pacientes originales.

El propio reto plantea como línea de trabajo prioritaria encontrar relaciones sólidas entre patologías asociadas a la diabetes que permitan predecir una patología antes de que sea diagnosticada, y en ediciones posteriores del mismo reto se reformula el objetivo de forma más directa: predecir eventos clínicos relevantes de la diabetes, como la ceguera o la cardiopatía, a partir del historial previo de diagnósticos. Es precisamente en esta línea, predicción y caracterización temporal de complicaciones asociadas a la diabetes a partir de la trayectoria de comorbilidades, donde se enmarca el análisis presentado en este documento.

2. Objetivo

El notebook procesa el dataset sintético de pacientes diabéticos del reto CAMDA 2023 (historiales de visitas codificados, en JSON) y lo transforma en tablas tabulares. El objetivo es caracterizar cuatro complicaciones de la diabetes: enfermedad renal crónica, cardiopatía isquémica, retinopatía diabética y amputaciones; desde tres ángulos complementarios: descriptivo (prevalencia y tiempos de evolución), predictivo (clasificación de riesgo) y de supervivencia (tiempo hasta el evento).

3. Datos y métodos

3.1. Preparación de los datos

Cada paciente aporta una lista de visitas; la primera codifica el sexo y las siguientes incluyen un código de edad (4 dígitos que empiezan por '9') junto con los diagnósticos de esa visita. Estos datos se aplanan a una tabla con una fila por diagnóstico (Paciente_ID, Sexo, Edad_Diagnostico, Codigo_Enfermedad). Tras un análisis de calidad (nulos, edades fuera de rango, incoherencias cronológicas) se aplica la limpieza definitiva: se descartan los pacientes sin diabetes, se recalcula la edad de debut de la diabetes por paciente y se eliminan los diagnósticos anteriores a esa edad, quedando la diabetes siempre como primer diagnóstico registrado. Se añade la columna Años_Desde_Diabetes, base temporal del resto de análisis.

3.2. Modelado predictivo y de supervivencia

Para cada complicación se construye un dataset con diseño landmark: el corte de cada paciente es la edad del evento (si ocurre) o la última edad registrada; solo se usan como predictoras las comorbilidades diagnosticadas hasta ese corte, excluyendo la diabetes y la propia complicación objetivo, lo que evita fuga de información. Sobre ese dataset se comparan: Regresión Logística (referencia simple) frente a XGBoost optimizado con Optuna (40 trials, CV estratificada a 4 folds, optimizando PR-AUC por el desbalanceo de clases); y, para el tiempo hasta el evento, Cox PH frente a Random Survival Forest, evaluados con el índice de concordancia (c-index).

3.3. Librerías principales

Librería	Uso
pandas / numpy	Manipulación de datos
seaborn / matplotlib	Visualización
scikit-learn	Preprocesado, Regresión Logística, métricas
xgboost + optuna	Clasificación avanzada y optimización de hiperparámetros
lifelines / scikit-survival	Cox PH, Kaplan-Meier, Random Survival Forest
umap-learn	Reducción de dimensionalidad

4. Resultados

4.1. Descripción de la cohorte

Tras la limpieza quedan 899.883 pacientes con diabetes (3.257.047 diagnósticos en total): 620.536 hombres (69,0 %) y 279.347 mujeres (31,0 %). La edad media de debut de la diabetes es 61,6 años (DE 13,1); las mujeres debutan de media más tarde que los hombres (64,5 vs. 60,3 años), aunque la edad más frecuente (moda) es mayor en mujeres (68 años) que en hombres (60 años).




Figura 1: Distribución de las enfermedades por sexo

4.2. Cormobilidad

De media, cada paciente acumula 3,62 enfermedades distintas (DE 2,34; mediana 3; máximo 28). Las patologías más frecuentes en toda la cohorte son hipertensión (48,0 %), hiperlipidemia (40,2 %) y artrosis/espondilosis (33,5 %); el patrón es similar por sexo, aunque la ansiedad y la artrosis son proporcionalmente más frecuentes en mujeres.




Figura 2: Número de enfermedades diagnosticadas por paciente

4.3. Prevalencia de las complicaciones objetivo

Complicación	Código	Hombres	Mujeres	Total
Retinopatía diabética	0703	41.644 (6,71 %)	26.134 (9,36 %)	67.778 (7,53 %)
Enf. renal crónica	1401	47.467 (7,65 %)	21.224 (7,60 %)	68.691 (7,63 %)
Cardiopatía isquémica	0910	43.942 (7,08 %)	18.766 (6,72 %)	62.708 (6,97 %)
Amputaciones	1999	0 (0,00 %)	0 (0,00 %)	0 (0,00 %)

En esta ejecución no aparece ningún caso de amputación (código 1999) en la cohorte, por lo que esta complicación queda fuera del modelado predictivo y de supervivencia. Las tres complicaciones restantes modeladas tienen una prevalencia muy similar entre sí (7,0–7,6 %), con la retinopatía notablemente

más frecuente en mujeres (9,4 % vs. 6,7 % en hombres) que las otras dos, donde la diferencia por sexo es menor.

4.4. Tiempo hasta la aparición de cada complicación

Complicación	Sexo	N	Media (años)	Mediana	DE
Enf. renal crónica	Hombre	47.467	6,6	6,0	5,9
	Mujer	21.224	7,7	7,0	6,3
Cardiopatía isquémica	Hombre	43.942	4,0	2,0	4,9
	Mujer	18.766	4,5	2,0	5,4
Retinopatía diabética	Hombre	41.644	5,5	4,0	5,3
	Mujer	26.134	6,2	5,0	5,8

La cardiopatía isquémica es, con diferencia, la complicación de aparición más rápida (mediana de solo 2 años desde el debut de la diabetes), mientras que la enfermedad renal crónica tarda más en desarrollarse (mediana 6–7 años). En las tres complicaciones las mujeres tardan, de media, algo más que los hombres en desarrollarlas.




Figura 3: Años hasta la complicación renal, por sexo.




Figura 4: Años hasta la cardiopatía isquémica, por sexo.

4.5. Modelado predictivo: Regresión Logística vs. XGBoost + Optuna

Complicación	N test	Preval. test	ROC-AUC (Simple)	PR-AUC (Simple)	ROC-AUC (XGBoost)	PR-AUC (XGBoost)
Renal	101.253	11,3 %	0,666	0,193	0,696	0,237
Cardíaca	98.954	7,7 %	0,684	0,138	0,715	0,211
Retina	100.612	10,6 %	0,702	0,228	0,726	0,279

En las tres complicaciones, XGBoost+Optuna mejora tanto el ROC-AUC como el PR-AUC frente a la Regresión Logística, y el PR-AUC de ambos modelos supera claramente la prevalencia base de cada complicación (p. ej. 0,237 vs. 0,113 en renal), lo que indica que sí aportan señal real y no solo reflejan la tasa base. Aun así, el PR-AUC absoluto se mantiene modesto (0,21–0,28 con XGBoost), lo que apunta, tal y como señala el propio notebook, a que las features actuales (solo comorbilidades binarias, edad y sexo) limitan más el rendimiento que la complejidad del modelo.

En la complicación cardíaca, XGBoost mejora el PR-AUC (0,138 → 0,211) pero, al umbral de decisión por defecto (0,5), el recall de la clase positiva cae a 0,01 (frente a 0,70 en el modelo simple). El modelo ordena mejor a los pacientes por riesgo, pero con ese umbral concreto apenas predice positivos: en un uso real

convendría ajustar el umbral en función de PR-AUC/recall deseado, no usar 0,5 por defecto.

4.6. Análisis de supervivencia: Cox PH vs. Random Survival Forest

Complicación	N eventos (test)	c-index (Cox PH)	c-index (RSF)
Renal	11.419	0,758	0,741
Cardíaca	7.604	0,755	0,757
Retina	10.677	0,746	0,749

El c-index es prácticamente idéntico entre Cox PH y Random Survival Forest en las tres complicaciones (diferencias $\leq 0,017$), y se sitúa en un rango moderado (0,74–0,76: por encima del azar, lejos de la discriminación perfecta). Que un modelo no lineal (RSF) no supere al lineal (Cox) sugiere que, con las features actuales, la relación entre comorbilidades y riesgo es mayoritariamente lineal, o que el techo de rendimiento lo marcan las features disponibles más que la forma funcional del modelo, en línea con lo observado en clasificación.

4.7. Exploración visual: UMAP de perfiles de comorbilidad

Sobre un embedding UMAP calculado a partir del perfil completo de comorbilidades (30.000 pacientes submuestreados, excluyendo las 3 complicaciones objetivo de las features) no se aprecia una separación visual clara entre los pacientes que desarrollan cada complicación y los que no: los puntos rojos ("Sí") aparecen mezclados con los azules ("No") en las tres vistas, sin formar regiones propias diferenciadas.




Figura 5: UMAP del perfil de comorbilidades, coloreado por aparición de cada complicación.

Esto es consistente con el rendimiento moderado de los modelos predictivos y de supervivencia: el perfil de comorbilidades por sí solo no separa claramente a los pacientes de alto y bajo riesgo, al menos en dos dimensiones.

4.8. Grafo causal de comorbilidades (MIIC)

Como complemento al modelado predictivo y de supervivencia, se utilizó el paquete de R `miic` (Multivariate Information-based Inductive Causation) para aprender un grafo de relaciones (causales/probabilísticas) entre comorbilidades a partir de la matriz binaria de comorbilidad. Sobre las 77 variables binarias originales se descartó primero Diabetes (prevalencia del 100 %, sin varianza) y después las variables con una prevalencia inferior al 1 %, quedando 32 comorbilidades más la edad de debut de la diabetes ($899.883 \text{ pacientes} \times 33 \text{ columnas}$). Sobre una muestra aleatoria de 20.000 pacientes se ejecutó `miic()` con 100 shuffles para estimar la confianza de cada relación y un umbral de confianza de 0,01 para descartar aristas poco fiables, obteniendo el grafo global de comorbilidades.




Figura 6: MIIC de todas las enfermedades diagnosticadas

Sobre ese grafo global se aisló el subgrafo formado por las tres complicaciones de interés (Chronic kidney disease, Ischemic heart disease, Retinopathy) junto con todos sus vecinos directos, para inspeccionar visualmente su entorno de comorbilidades.




Figura 7: Subgrafo MIIC de las tres complicaciones de interés y sus comorbilidades vecinas (en naranja, las tres complicaciones)

El análisis de vecindad muestra que hipertensión e hiperlipidemia son las dos únicas comorbilidades conectadas simultáneamente con las tres complicaciones, lo que las señala como los nodos más transversales del grafo. Además, existe una arista directa entre Chronic kidney disease e Ischemic heart disease, es decir, el grafo capta una relación directa entre la propia enfermedad renal y la cardiopatía isquémica, más allá de sus factores de riesgo compartidos. La enfermedad renal es la que más comorbilidades exclusivas tiene (no compartidas con cardiopatía ni retinopatía): además de la propia cardiopatía isquémica, aparecen EPOC, esteatosis hepática, gota/enfermedades por depósito de cristales y enfermedades cardíacas adquiridas, un perfil compatible con comorbilidad cardiometabólica y renal avanzada.




Figura 8: Diagrama de Venn entre las tres enfermedades de interés

5. Discusión y conclusiones

- **Carga de enfermedad considerable pero heterogénea:** con una media de 3,6 comorbilidades por paciente y patologías cardiometabólicas (hipertensión, hiperlipidemia) como las más prevalentes, la cohorte refleja el perfil esperado de una población diabética de larga evolución.
- **Las tres complicaciones modeladas tienen prevalencias parecidas (7–7,6 %) pero dinámicas temporales distintas:** la cardiopatía isquémica aparece mucho antes (mediana 2 años) que la enfermedad renal (mediana 6-7 años), lo que sugiere que el seguimiento clínico de cada complicación debería tener una cadencia distinta.
- **El modelado aporta señal real pero limitada:** tanto en clasificación (PR-AUC por encima de la prevalencia base) como en supervivencia (c-index 0,74-0,76), los modelos superan claramente el azar, pero están lejos de un rendimiento alto. El techo parece estar en las *features* (comorbilidades binarias + edad + sexo) más que en el algoritmo: XGBoost mejora a la Regresión Logística de forma modesta, y RSF no supera a Cox PH.
- **El umbral de decisión importa tanto como el modelo:** el caso de la complicación cardíaca (*recall* casi nulo al umbral 0,5 pese a mejor PR-AUC) es un recordatorio de que, con clases tan desbalanceadas, el umbral de clasificación debe ajustarse explícitamente y no dejarse en el valor por defecto.
- **El grafo MIIC apunta a hipertensión e hiperlipidemia como nodos transversales:** son las únicas comorbilidades conectadas a la vez con las tres complicaciones de interés, y aparecen también entre las variables con mayor peso en el modelado predictivo y de supervivencia —una coincidencia entre métodos que refuerza la relevancia clínica de ambos factores como objetivo de control temprano.
- **Próximos pasos naturales:** enriquecer las *features* (combinaciones de comorbilidades, otras ventanas temporales, variables de intensidad de uso del sistema sanitario), re-ejecutar de forma continua las celdas de supervivencia y de MIIC que fallaron o quedaron sin confirmar reproducibilidad para obtener las curvas de Kaplan-Meier, el *forest plot* de *hazard ratios* y el grafo causal de retinopatía, y aclarar los puntos pendientes.

6. Limitaciones

- El dataset es sintético, por lo que los patrones observados reflejan el proceso de generación de datos y no necesariamente la epidemiología real de la diabetes
- Hay un fuerte desbalanceo de sexo en la cohorte (69 % hombres / 31 % mujeres); no se ha explorado si responde a un sesgo del generador de datos o a un criterio de inclusión
- Las complicaciones de amputación no tienen ningún caso registrado en esta ejecución, por lo que quedan fuera de todo el análisis cuantitativo